

基于多模型融合的 NIPT 时点优化与异常判定研究

摘要

无创产前检测 (NIPT) 技术的广泛应用对保障母婴健康具有重要意义, 但其检测时点的选择与异常判定的准确性仍是亟待优化的关键问题。为此, 本文基于临床检测数据, 通过建立一系列递进式的数学模型, 为 NIPT 的个体化与精准化应用提供了完整的解决方案。

针对问题一, 为探究 Y 染色体浓度的核心影响因素, 本文首先通过探索性数据分析识别出两个关键挑战: 数据存在重复测量结构, 且因变量 Y 染色体浓度呈有界偏态分布。为妥善处理这一数据结构, 研究采用对 Y 浓度进行 Logit 变换以满足线性模型假设, 进而构建能够科学处理个体差异的**线性混合效应模型**, 并采用**极大似然估计**进行求解。最终, 模型结果清晰地揭示了问题的核心结构: 在控制了测序质量等协变量后, BMI 是显著的负向影响因素; 更重要的是, 方差分解表明由孕妇个体差异 (随机效应) 解释的方差占总变异的绝大部分 (**条件 $R^2 > 0.8$**)。这一发现证明了个体异质性是影响 Y 浓度的最主要来源, 为后续问题必须采用能够处理个体差异的模型奠定了坚实的理论基础。

针对问题二, 为给男胎孕妇制定 NIPT 时点优化策略, 本文将 Y 染色体浓度达标判定转化为二元分类问题, 并基于**广义线性混合模型**建立达标概率预测模型。为确定最优 BMI 分组方案, 创新性地引入**动态规划算法**, 以最小化组内风险加权方差为优化目标进行全局最优分割。最终将孕妇群体划分为五个最优 BMI 区间, 并给出精细化 NIPT 时点**推荐方案**: BMI 低于 33.8 kg/m^2 的孕妇推荐第 12 周检测; 随着 BMI 升高, 检测时点相应推迟, BMI 高于 36.5 kg/m^2 的群体建议推迟至第 16 周左右检测。该方案在保证检测准确性的前提下实现了临床风险的最小化。

针对问题三, 为进一步提升决策精度, 本文将问题框架转换为动态的**首次达标时间**预测问题, 建立**梯度提升生存模型**刻画多因素联合影响。创新性地提出均衡型与保障型**双策略决策机制**, 并再次运用**动态规划算法**进行最优分割求解。最终形成的双轨制推荐方案能够有效平衡检测效率与临床可靠性, 典型如 BMI 高于 29.2 kg/m^2 的群体: 保障型策略建议第 16 周检测以确保可靠性, 均衡型策略则建议第 12 周检测以兼顾时效性。

针对问题四, 为解决女胎异常判定的高度不平衡分类难题, 本文基于 **TabNet** 架构的深度学习模型, 引入 **Focal Loss** 损失函数缓解类别不平衡问题, 并采用 **F2-score 最大化准则**自适应确定最优决策阈值。最终, 构建了一套测试集 AUC 达 0.845、最优阈值 0.58 的集成模型预测与辅助质控环路的**三层闭环智能判定系统**。实验表明, 相较基线模型, 该系统漏诊数降低 25%, 显著提升了筛查安全性。

关键字: NIPT 时点选择 生存分析 动态规划 TabNet 类别不平衡

一、问题重述

1.1 问题背景

随着精准医疗技术的飞速发展以及大众健康意识的普遍增强，[1] 无创产前检测 (NIPT) 作为一项前沿的基因检测技术，在预防出生缺陷、保障母婴健康领域发挥着日益关键的作用，同时也面临着更高的应用需求与优化挑战。其核心挑战在于：如何在确保检测结果准确性的硬性前提下，尽可能地提前发现胎儿染色体异常，以争取宝贵时间窗口。通过建立数据驱动的 NIPT 检测时点优化策略，不仅能有效提升筛查效率、降低漏诊风险，更能保障母婴生命安全。因此，构建一个能够融合多维度生理特征与先进数学模型的科学决策体系，既是应对当前临床挑战的必然要求，也是推动 NIPT 技术向个体化、精准化、智慧化发展的关键路径。

本文的研究基于附件所提供的某地区孕妇 NIPT 临床检测数据。该数据集具有鲜明的现实特征：样本主体为高身体质量指数 (BMI) 孕妇群体。这一特征为我们深入研究特定人群（尤其是高 BMI 人群）的 NIPT 时点选择与异常判定问题，提供了极具针对性的数据基础。

在此现实背景下，问题的求解需遵循几个关键约束。首先，NIPT 检测准确性存在明确的生物阈值：对于男胎，Y 染色体浓度需达到或超过 4% 方可认为结果可靠；对于女胎，则需 X 染色体浓度未见异常。其次，临床风险与发现时间密切相关：孕 12 周以内发现为低风险，13–27 周为高风险，28 周以后则为极高风险。这构成了本研究需要解决的核心矛盾：必须在“等待足够时间以满足检测浓度要求”与“尽早检测以规避高风险”之间寻求最优平衡。。

此外，实际应用中还存在诸多不确定因素，如个体生理差异、测序技术波动等，这些都要求模型具备良好的鲁棒性。综上所述，针对上述复杂的临床需求、数据特征与约束条件，本研究旨在构建一套系统的数学模型体系。该体系需综合考量孕妇孕周、BMI、年龄、身高、体重等生理特征以及测序数据质量指标，核心目标是为不同特征的孕妇群体提供一套能够使其潜在临床风险最小化的、科学且可靠的个体化 NIPT 决策方案。

1.2 基本问题

基于上述背景，本研究旨在利用附件提供的数据，建立数学模型解决以下四个问题：

问题 1 分析并建立一个能够描述胎儿 Y 染色体浓度与孕妇孕周、BMI 等生理指标之间关系的数学模型，并检验其统计显著性。

问题 2 要求以 BMI 为核心影响因素，对男胎孕妇进行合理分层，并为每个群体确定一个能使潜在风险最小化的最佳 NIPT 检测时点，同时分析检测误差对结果的影响。

问题 3 要求在问题二的基础上，综合考虑身高、体重、年龄等多维因素，并结合达标比例与检测误差，重新对男胎孕妇进行 BMI 分组，并确定最佳检测时点，以实现更精细化的风险控制。

问题 4 针对女胎孕妇，构建一个综合利用 Z 值、GC 含量、读段数、BMI 等多维度信息的智能判别模型，用以准确判断其胎儿是否存在 13、18、21 号染色体非整倍体异常。

为系统性地解决上述问题，本文构建了一套层层递进的建模与求解方案，其整体框架如下：




图 1 总流程图

二、模型假设

1. **数据代表性假设**：假设附件所提供的临床检测数据真实、准确，具有统计代表性。数据预处理流程（如缺失值处理、异常值剔除）科学合理，不会引入系统性偏差，足以支撑后续建模分析。
2. **临床标准有效性假设**：假设题目中给定的临床判定标准为当前公认的有效依据。这包括：（1）男胎 Y 染色体浓度 4% 的达标阈值；（2）基于孕周（早期 ≤ 12 周，中期 13–27 周，晚期 ≥ 28 周）的临床风险分级；（3）附件中提供的染色体非整倍体（AB 列）标签真实可靠，可作为模型训练与验证的基准。
3. **个体差异的可建模性**：假设同一孕妇多次检测数据间的相关性（非独立性）可通过引入随机效应（如随机截距）进行刻画；不同孕妇间的异质性（如基线浓度差异）是显著且可被量化的。
4. **核心变量充分性假设**：假设本研究选取的特征变量（如孕周、BMI、年龄、测序质量指标等）是影响 NIPT 检测结果（Y 染色体浓度、异常判定）的核心且主要的因素。暂未考虑饮食、遗传、环境等未观测或未提供的潜在混杂因素，其影响可被纳入模型残差项。
5. **风险成本非对称性假设**：假设在女胎染色体异常判定中，漏诊（将异常误判为正常）的临床后果远重于误诊（将正常误判为异常）。因此，模型优化须以最大化召回率（Recall）为首要目标，该假设是选用 F2-Score 作为模型评估与阈值优化准则的根本依据。

三、符号说明

表 1 主要符号及其说明

符号	说明
业务变量与指标	
Y_{ij}	第 i 位孕妇在第 j 次检测时的 Y 染色体浓度（连续值）
gw	孕妇的检测孕周（单位：周）
BMI	孕妇的身体质量指数
τ	Y 染色体浓度的临床达标阈值，本文取 $\tau = 4\%$
Z_{ij}	Y 浓度是否达标的二元（0/1）事件（问题二）
Z_c	第 c 号染色体的 Z 值（Z-score），核心判别特征（问题四）
生存分析重要符号	
T_i	第 i 位孕妇的“首次达标孕周”，即生存分析中的事件时间
δ_i	第 i 位孕妇的删失指示符（1= 事件发生，0= 右删失）
X	代表孕妇多维特征（BMI、年龄、测序指标等）的向量
$H(t X)$	累积风险函数，表示特征为 X 的孕妇到孕周 t 时的累积风险
$S(t X)$	生存函数，由 $H(t X)$ 导出，表示在孕周 t 时仍未达标的概率
模型与决策关键符号	
b_i	代表第 i 位孕妇个体特异性的随机截距
σ_u^2	随机截距 b_i 的方差，衡量个体间差异的大小
ε_{ij}	线性混合模型中的随机误差项
σ^2	随机误差项 ε_{ij} 的方差，衡量模型未能解释的变异
β	线性模型中的固定效应系数向量
p_{ij}	GLMM 模型预测的达标概率
p^*	“保障型”策略中，设定的目标达标概率阈值（如 90%）
K	动态规划分组优化模型中，设定的最终分组数量
$w(g_i)$	与推荐孕周 g_i 相关的临床风险权重函数
$C_G(t)$	“均衡型”决策策略中，分组 G 在孕周 t 的总成本函数
γ	Focal Loss 损失函数中的聚焦参数，用于调节难易样本权重
$F2\text{-score}$	用于优化分类阈值、侧重于高召回率的评估指标

四、问题一的模型建立和求解

4.1 问题分析

问题一的核心在于，利用附件提供的临床数据，在满足数据真实可靠等基本假设的前提下，精准量化胎儿 Y 染色体浓度与孕妇孕周、BMI 等关键指标间的关系，并构建一个能够解释并预测该浓度变化规律的关系模型。本节整体思路是从数据探索性分析出发，构建并求解一个能够应对数据复杂性的统计模型，并最终对模型结果进行解释与检验。

具体而言，本节首先对 Y 染色体浓度、孕妇孕周、BMI 以及关键测序质量指标的分布及相互关系进行了可视化分析。通过绘制直方图、散点图及相关性热力图，我们初步探明了变量的分布特征如 Y 浓度的右偏有界性与潜在趋势如 Y 浓度随孕周大致呈正相关，随 BMI 大致呈负相关。这些可视化结果为后续构建关系模型时变量的选择、变换形式的确定以及交互作用的假设提供了扎实的经验数据支持。

随后，针对问题一的主要难点——即数据中同一孕妇多次检测的纵向结构和因变量 Y 浓度的有界偏态性，[2] 本节构建了一个线性混合效应模型。该模型综合考虑了多个关键因素：其固定效应部分纳入了孕周、BMI、年龄、测序质量等协变量，并包含了孕周与 BMI 的交互项，以检验 BMI 对孕周效应的调节作用；此外，为应对数据的嵌套结构，模型还考虑了以孕妇 ID 为单位的随机截距效应这一特殊要求，以准确捕捉个体间的异质性。

接下来，我们采用基于极大似然估计的迭代估计算法，针对上述模型进行参数求解，得出了各影响因素对 Y 染色体浓度的效应大小及其统计显著性水平。该关系模型的结果通过参数估计表进行了清晰呈现。最终，通过绘制残差诊断图并分析模型的边际与条件 R^2 ，我们深入验证了模型的拟合优度与可靠性，并对各变异来源的贡献度进行了量化分析。

4.2 数据预处理与特征工程

为确保后续建模的准确性与可靠性，并满足模型假设，我们对原始数据进行了一系列严格的预处理与特征工程，主要步骤如下：

- **数据清洗与筛选：**我们首先对数据集进行清洗，仅保留男胎样本，并剔除其他关键变量如孕周、BMI 等存在缺失或逻辑异常的记录，以确保分析基础的可靠性。
- **因变量处理（Logit 变换）：**考虑到因变量 Y 染色体浓度是位于 (0,1) 区间的比例数据且呈偏态分布，我们对其进行截断与 Logit 变换，[3] 将其映射至整个实数域 $(-\infty, +\infty)$ ，以满足线性模型对因变量正态性与同方差性的要求。

$$Y^* = \min(\max(Y, \varepsilon), 1 - \varepsilon), \quad \tilde{Y} = \text{logit}(Y^*) = \ln \frac{Y^*}{1 - Y^*}, \quad \varepsilon = 10^{-4}$$

- **数据格式转换与变换：**我们将“11w+6”等文本格式的孕周，统一转换为数值型连续变量；同时，为缓解部分变量的长尾分布，对“唯一比对读段数” (*uniq*) 特征进行了对数变换。
- **交互项创建：**为检验 BMI 对孕周效应的调节作用，即探究高 BMI 是否会减缓 Y 浓度的增长速度，我们创建了核心的 $gw \times BMI$ 交互项。
- **协变量纳入：**我们将年龄、GC 含量等其他与 Y 浓度相关的生理或技术指标，作为协变量一并纳入模型，以控制潜在的混杂因素，更纯净地估计核心变量的效应。
- **特征标准化 (z-score)：**为消除各变量间因量纲不同可能导致的模型偏差，并便于后续对各因素效应大小进行比较，我们对所有连续型自变量（包括新创建的交互项）均进行了 z-score 标准化处理。

$$x_z = \frac{x - \bar{x}}{s_x}$$

4.3 数据探索性分析

本小节对孕周、Y 染色体浓度、BMI 及测序质量指标等关键变量进行了系统的探索性分析，其分布特征与相关关系为后续模型构建中的变量选择、函数形式设定及统计方法适用性提供了关键的数据依据与理论支撑。

(I) 孕周分布特征图 孕周分布特征如图2所示，其值主要集中于 12-22 周区间，且呈现多峰分布特点。这表明数据采集并非在等距时间点上进行，但所幸覆盖了早期与中期妊娠这一临床关注的关键窗口。此分布特征支持将孕周作为连续型自变量处理，以捕捉其与响应变量之间的潜在趋势关系。




图2 样本中孕妇孕周分布

(II) Y 染色体浓度分布特征图 (Y) 的分布则表现出更为特殊的形态 (图3)。其分布显著右偏，且绝大多数观测值集中于 0.02-0.12 区间内，同时受到 [0, 1] 物理边界的严格

约束。若直接在此线性尺度上建立回归模型，极易导致异方差与越界预测。因此在建模时先对 Y 做极小截断再采用 $\tilde{Y} = \log \frac{Y}{1-Y}$ 的对数几率变换；该处理把均值-线性预测子的关系拉直，同时把方差结构稳定在可接受范围内，为随后使用线性混合效应框架打下基础




图3 Y 染色体浓度分布

(III) 数据相关矩阵热力图 相关矩阵如图4显示， Y 与孕周呈整体正相关、与 BMI 呈整体负相关，而两者与测序质量指标 (GC、比对比例、重复率、uniq)) 之间的相关度普遍较弱, 这意味着把生物学变量与质量协变量同时纳入同一方程不会引发严重的多重共线性风险，支持了构建多元模型的可行性。




图4 样本中孕妇孕周分布、Y 染色体浓度分布

(IV) 染色体浓度与孕周、BMI 散点图 图5与图6的散点图直观地展示了 Y 染色体浓度与 BMI 和孕周的核心关系。从图5可见， Y 染色体浓度随 BMI 升高呈现显著的下降趋

势，这为模型中设定 BMI 为负向主效应提供了直接依据。而图6则显示，浓度随孕周增加有清晰的上升趋势，尤其是在几个数据密集区间内，为模型设定孕周为正向主效应提供了视觉支持。

综合两图，一个核心的建模问题浮现：BMI 的影响仅仅是拉低了浓度的整体基线水平，还是会进一步减缓其随孕周增加的增长速度？为精准回答这一问题，我们在后续的模型中专门引入了 BMI 与孕周的交互项进行检验。




图 5 Y 染色体浓度与 BMI 散点图




图 6 Y 染色体浓度与孕周散点图

4.4 线性混合效应模型建立

为系统应对重复测量数据结构与响应变量有界偏态分布两大核心挑战，本研究构建了线性混合效应模型框架。具体而言，模型通过为每位孕妇引入随机截距，有效刻画并分离了同一主体多次测量数据间的组内相关性，从而克服传统 OLS 回归因忽略数据结构而导致的估计偏误，确保参数估计的无偏性与稳健性。同时，为准确估计孕周、BMI 等核心生物学自变量的纯净效应，模型将 GC 含量、比对比例等测序质量指标作为固定效应协变量纳入，以控制技术层面混杂因素带来的噪音干扰。该建模策略为实现 Y 染色体浓度影响因素的精准量化奠定了严谨的方法学基础。

(I) 固定效应部分 固定效应部分包含了所有被试间一致的总体平均效应，其线性预测项定义如下：

$$X_{ij}\beta = \beta_0 + \beta_1 gw_{z,ij} + \beta_2 BMI_{z,ij} + \beta_3 (gw \times BMI)_{z,ij} + \sum_{k=4}^8 \beta_k x_{k,ij} \quad (1)$$

其中， $X_{ij}\beta$ 表示固定效应部分，包含了标准化后的孕周 (gw_z)、BMI (BMI_z)、其交互项 ($(gw \times BMI)_z$) 以及其他标准化协变量，包括年龄、GC 含量、比对比例、重复率、唯一比对读段数 $\log uni$ 。

(II) 随机效应部分 随机效应部分用于刻画个体间的特异性差异：

$$b_i \sim \mathcal{N}(0, \sigma_u^2), \quad \varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2) \quad (2)$$

式中, b_i 为随机截距, 表征第 i 位孕妇的个体特异性; ε_{ij} 为随机误差项。

(III) 完整模型 设第 i 位孕妇在第 j 次检测的响应 (经 Logit 变换后的 Y 染色体浓度) 为 $\tilde{Y}_{ij}$, 则建立的线性混合效应模型如下:

$$\begin{cases} \tilde{Y}_{ij} = X_{ij}\beta + b_i + \varepsilon_{ij} \\ X_{ij}\beta = \beta_0 + \beta_1 gw_{z,ij} + \beta_2 BMI_{z,ij} + \beta_3 (gw \times BMI)_{z,ij} + \sum_{k=4}^8 \beta_k x_{k,ij} \\ b_i \sim \mathcal{N}(0, \sigma_u^2), \quad \varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2) \end{cases} \quad (3)$$

4.5 参数估计与结果解释

本小节旨在对线性混合效应模型的参数估计结果进行系统阐释, 其分析结论直接回应了孕周、BMI 及测序质量指标对 Y 染色体浓度的定量影响。具体而言, 首先采用限制极大似然估计 (REML) 算法进行模型拟合, 在确保估计精度与稳定性的基础上, 得到了固定效应与随机效应的无偏估计值。随后, 通过计算各变量的回归系数、置信区间及 p 值, 量化了不同因素对 Y 染色体浓度的效应大小与统计显著性, 并进一步基于估计结果验证了前期关于变量间交互作用的科学假设。最终, 通过对随机效应方差分量的解读, 揭示了孕妇个体水平变异对模型解释力的贡献程度, 为理解浓度差异的来源提供了多层次、可解释的数据依据。

I. 参数估计方法 为估计模型中的固定效应系数 β 以及方差分量 σ_u^2 和 σ^2 , 我们采用基于边际似然的极大似然估计 (MLE) 方法。该方法首先通过数学上的积分运算, 将模型中不可观测的随机效应 b_i 消除, 从而得到一个仅依赖于待估参数的边际对数似然函数。

考虑到模型中的随机效应 b_i , 第 i 位孕妇的响应变量 $\tilde{\mathbf{Y}}_i$ 的边际分布为一个多元正态分布:

$$\tilde{\mathbf{Y}}_i \sim \mathcal{N}(\mathbf{X}_i\beta, \mathbf{V}_i), \quad \text{其中 } \mathbf{V}_i = \sigma_u^2 \mathbf{1}\mathbf{1}^\top + \sigma^2 \mathbf{I} \quad (4)$$

其中 $\mathbf{V}_i$ 为该孕妇观测向量的边际协方差矩阵, 它内生性地刻画了由个体差异所导致的组内相关性。

相应的边际对数似然函数 (Log-Likelihood Function) ℓ 则表示为:

$$\ell(\beta, \sigma_u^2, \sigma^2) = -\frac{1}{2} \sum_{i=1}^N \left[\log |\mathbf{V}_i| + (\tilde{\mathbf{Y}}_i - \mathbf{X}_i\beta)^\top \mathbf{V}_i^{-1} (\tilde{\mathbf{Y}}_i - \mathbf{X}_i\beta) + n_i \log(2\pi) \right] \quad (5)$$

由于该似然函数没有解析解, 我们必须采用数值优化算法来寻找使其最大化的参数值。在本次研究中, 我们明确指定了采用极大似然估计 (MLE), 并选用高效的拟牛顿法——L-BFGS 算法作为优化器, 通过迭代计算, 最终得到收敛的参数估计值 $\hat{\beta}, \hat{\sigma}_u^2, \hat{\sigma}^2$ 。

II. 方差分解与解释度评估 为量化模型对变异来源的解释程度，基于 Nakagawa 的方法进行计算。记固定效应解释的方差为 $V_F = \text{Var}(X_{ij}\hat{\beta})$ ，随机截距方差为 $V_R = \hat{\sigma}_u^2$ ，残差方差为 $V_\epsilon = \hat{\sigma}^2$ 。则边际 R^2 与条件 R^2 定义如下：

$$R^2_{\text{marginal}} = \frac{V_F}{V_F + V_R + V_\epsilon}, \quad R^2_{\text{conditional}} = \frac{V_F + V_R}{V_F + V_R + V_\epsilon} \tag{6}$$

前者衡量固定效应的解释力，后者将个体差异一并计入。

III. 参数估计结果 线性混合效应模型的详细参数估计结果如表2所示。通过对该表的深入解读，我们得到了关于 Y 染色体浓度影响因素的三个核心洞察。

表 2 线性混合效应模型参数估计结果

参数	系数	标准误	z 值	p 值
固定效应				
截距	-2.570	0.027	-93.673	< 0.001***
孕周（标准化）	0.062	0.095	0.656	0.512
BMI（标准化）	-0.120	0.046	-2.583	0.010**
孕周 × BMI 交互	0.144	0.108	1.336	0.181
年龄（标准化）	-0.048	0.028	-1.746	0.081
GC 含量（标准化）	0.021	0.010	2.145	0.032*
比对比例（标准化）	-0.010	0.009	-1.123	0.261
重复率（标准化）	0.002	0.009	0.248	0.804
log(唯一读段数)（标准化）	-0.039	0.010	-4.061	< 0.001***
随机效应				
个体间方差（Group Var）	0.183	0.078	-	-
残差方差	0.068	-	-	-

注：* $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$

- 生理因素的效应分析：**模型结果证实，BMI 的效应（系数 = -0.120, $p = 0.010$ ）显著为负，即 BMI 越高的孕妇其 Y 浓度基线水平越低。同时发现，孕周的主效应（ $p = 0.512$ ）及其与 BMI 的交互效应（ $p = 0.181$ ）均不显著，这表明其宏观趋势可能被更强的个体因素所掩盖。
- 测序质量指标的显著影响：**模型同时证实，测序质量指标对 Y 浓度具有显著影响，例如 GC 含量（ $p = 0.032$ ）呈正效应，而唯一比对读段数的对数（ $p < 0.001$ ）呈负

效应。这表明我们的模型成功地控制了技术性变异，从而能更纯净地评估核心生理因素的影响。

- **个体差异的主导作用：**最终，模型最重要的发现来自于其方差组成。代表个体基线差异的个体间方差 ($\sigma_u^2 = 0.183$) 远大于模型未能解释的残差方差 ($\sigma^2 = 0.068$)。这在数量上证明了“孕妇是谁”这一随机因素，是导致 Y 浓度差异的最主要因素，其影响力远超所有固定效应。这一发现揭示了问题的复杂性，并凸显了采用混合效应模型进行刻画的必要性。

IV. 方差分解 为量化模型中对变异来源的解释程度，本研究计算了边际 R^2 与条件 R^2 。结果表明，固定效应（包括孕周、BMI、交互项及其他协变量）共同解释了因变量（Logit 变换后的 Y 染色体浓度）总变异的 15.17%（边际 $R^2 = 0.152$ ）。然而，当同时考虑固定效应与随机效应（孕妇个体随机截距）时，模型可解释的总变异比例大幅提升至 81.01%（条件 $R^2 = 0.810$ ）。

表 3 线性混合效应模型方差分解结果

指标	数值	解释的变异来源
边际 R^2	0.152	固定效应（孕周、BMI、交互项、协变量）
条件 R^2	0.810	固定效应 + 随机效应（个体截距）

第一，固定效应所代表的共性生物学因素及技术协变量对 Y 浓度变异具有一定的解释力，但并非主导因素；第二，随机效应捕获的个体间差异（即不同孕妇自身的特异性）解释了绝大部分变异，这表明孕妇个体基线水平的高度异质性是数据中最主要的变异来源。边际与条件 R^2 之间的巨大差异 ($\Delta R^2 = 0.658$) 强烈支持了采用混合效应模型的必要性，证实了忽略个体随机效应将导致模型遗漏关键变异来源。

4.6 模型评估与诊断

为系统验证线性混合效应模型的理论假设并客观评估其拟合优度，本小节开展了全面的残差分析。模型的统计可靠性严格建立在误差项 ε_{ij} 满足独立同分布且服从正态分布 $\mathcal{N}(0, \sigma^2)$ 的核心假设之上，残差分析是检验该假设是否成立、进而保证模型推断科学性的关键依据。

I. 残差分析 图7与图8分别展示了标准化残差的正态 QQ 图及残差与拟合值的散点图。




图7 残差 QQ 图




图8 残差 vs 拟合值

- **正态性检验：**如图7所示，标准化残差数据点整体沿理论直线分布，仅在两端出现轻微偏离，这属于对受限变量进行线性建模时的常见现象；表面在 logit 尺度上，误差项的正态性假设基本合理。
- **同方差性与线性检验：**如图8所示，残差比较均匀分布在零点线两侧，其波动范围不随拟合值的变化而呈现明显的扩张、收缩或弯曲趋势，这表明数据未表现出明显的异方差性或强非线性模式，模型设定的线性形式足以捕捉当前数据范围内的主要趋势。

II. 模型稳健性结论 综合残差分析的结果，本研究构建的线性混合效应模型满足正态性与方差齐性的核心假设，且结果与前述方差分解中随机效应解释了绝大部分变异的结论相互印证，共同支持了采用混合效应模型而非普通线性回归的决策，确保了参数估计与统计推断的有效性。

五、问题二的模型建立和求解

5.1 问题分析

本小节的核心任务是为携带男胎的孕妇群体，制定一套数据驱动的 NIPT 时点优化策略。具体而言，我们需要依据孕妇的 BMI 进行合理分组，并为每个组别推荐一个能够使得潜在风险最小化的最佳 NIPT 检测时点。为实现此目标，关键在于将潜在风险最小化这一临床诉求，转化为一个定义清晰、可量化求解的数学优化问题。

首先，我们将临床上 Y 染色体浓度达到或超过 4% 的准确性判据，严格定义为一个二元的达标事件，记为 $Z_{ij} = 1$ 。这个定义是后续所有概率建模的基石。基于此，风险最小化策略便可具体化为：在确保达标事件发生概率不低于某一高置信水平 p^* 的前提下，寻找并推荐尽可能早的检测孕周。这一策略精准地平衡了临床上对检测可靠性的要求，以及对规避晚期发现风险的迫切需求。

接下来，我们规划的技术路线分为三步：第一，我们将继承问题一的混合效应框架，建立一个广义线性混合模型 (GLMM)，以精准刻画达标概率随孕周和 BMI 变化的动态规律；第二，从该概率模型中，我们将反解出满足特定置信水平 p^* 要求的最早孕周函数 $gw^*(BMI; p^*)$ ；最终，我们将该函数作为输入，应用动态规划这一优化算法，对连续的 BMI 进行最优分层，为每个群体推荐一个统一的最佳检测时点，从而形成一套科学、可行的临床决策方案。

5.2 模型建立

本小节旨在构建一个基于 BMI 分层的 NIPT 检测时点二元决策优化模型，为临床问题何时检测提供明确、可操作的分类建议。具体而言，首先将问题一中连续的 Y 染色体浓度转化为二元响应变量，并建立广义线性混合模型以估计特定孕周和 BMI 下的达标概率。随后，基于广义线性模型输出定义最早达标孕周函数，将其作为动态规划分组模型的输入，最终通过对连续 BMI 值进行最优离散化分割，得到兼具临床可解释性与操作性的分层检测方案。

5.2.1 广义线性混合模型的建立

为直接响应是否达标这一核心临床决策问题，我们首先需要将模型的预测目标进行转化。我们将问题一中连续的 Y 染色体浓度 (Y_{ij})，根据题目设定的 4% 临床阈值，转化为一个能够直接代表成功或失败的二元 (0/1) 事件变量 Z_{ij} 。其数学定义如下：

$$Z_{ij} = \begin{cases} 1, & \text{if } Y_{ij} \geq 0.04 \quad (\text{检测达标}) \\ 0, & \text{if } Y_{ij} < 0.04 \quad (\text{检测未达标}) \end{cases} \quad (7)$$

此转化的优势在于，它将一个复杂的连续值回归问题，转化为直接的二分类概率估计问题，使之与“是否达标”的临床决策目标相匹配。

考虑到 Z_{ij} 为二分类变量，且数据存在重复测量的层次结构（同一孕妇多次检测），我们构建广义线性混合模型。模型设定如下：

$$\text{logit}(P(Z_{ij} = 1)) = \eta_{ij} = X_{ij}\beta + b_i \quad (8)$$

$$b_i \sim \mathcal{N}(0, \sigma_b^2) \quad (9)$$

其中， $P(Z_{ij} = 1)$ 表示第 i 位孕妇第 j 次检测达标的概率； $\text{logit}(p) = \ln(\frac{p}{1-p})$ 为链接函数； $X_{ij}\beta$ 为固定效应部分，其变量组成与问题一保持一致，包含了标准化后的孕周 (gw_z)、BMI (BMI_z)、其交互项 ($(gw \times BMI)_z$) 及其他技术协变量（年龄、GC 含量、比对比例、重复率及 $\log(\text{uniq})$)； b_i 为代表第 i 位孕妇个体差异的随机截距。

基于已建立的 GLMM 模型，我们可以得到一个关键的输出函数，即最早达标孕周函数：

$$gw^*(\text{BMI}; p^*) = \inf \{ gw \in [10, 25] \mid \hat{p}(gw, \text{BMI}) \geq p^* \} \quad (10)$$

该函数的物理意义是：对于给定 BMI 值的孕妇，为使其检测达标概率至少达到预设的临床置信水平 p^* （0.90 或 0.95），所需选择的最早孕周。此函数将作为后续分组优化模型的直接输入。

5.2.2 基于动态规划的分组优化模型

在获得连续的“最早达标孕周”函数 $gw^*(\text{BMI})$ 后，为将其转化为可供临床应用的离散分组方案，我们需要确定最优的分组数量 K 与相应的分割点。根据相关临床分层管理的实践经验，通常将人群划分为 4 至 5 个层级。[4] 为兼顾方案的精细度与临床可操作性，本文设定目标分组数量 $K = 5$ 。

为确保这 5 个分组的划分方式在数学上达到最优，而非简单的人为设定，我们构建了一个基于动态规划的优化模型。该模型以最小化各分组内部的风险加权方差为目标，对这一维最优分割问题进行求解，从而保证最终的五层分组方案是全局最优的。

(I) 模型目标 该模型的核心是寻找一组最优的 BMI 分割点，将孕妇群体划分为 K 个离散的组别。最优化的准则是最小化所有分组内部推荐孕周的总风险加权方差。该方差度量了组内个体推荐孕周围绕组中心值的离散程度；方差越小，代表组内成员的同质性越高，使用同一个推荐孕周就越合理。我们引入了与孕周相关的风险权重的权重体系，使得模型在优化过程中赋予高风险时段的样本更高的权重，从而使最终的分组方案能够优先规避高临床风险，符合潜在风险最小化的题目要求。

(II) 模型数学构建 模型的数学构建包含以下要素：

- **输入数据：**在 BMI 的有效分布区间内进行离散化采样，得到一个有序的 BMI 序列 $B = \{b_1, b_2, \dots, b_n\}$ 。对于序列中的每个点 b_i ，其对应的推荐孕周为 $g_i = gw^*(b_i; p^*)$ ，其中 p^* 为预设的基准置信水平，由此构成推荐孕周序列 $G = \{g_1, g_2, \dots, g_n\}$ 。
- **风险权重函数：**为将临床风险认知量化并融入优化目标，我们定义一个与孕周 g_i 相关的分段风险权重函数 $w(g_i)$ 。该函数依据题目中关于早期、中期、晚期风险递增的描述设计：

$$w(g_i) = \begin{cases} 1.0, & g_i \leq 12 \quad (\text{低风险期}) \\ 2.0, & 12 < g_i < 28 \quad (\text{中风险期}) \\ 4.0, & g_i \geq 28 \quad (\text{高风险期}) \end{cases} \quad (11)$$

权重随孕周增加而递增，使得优化过程更倾向于减少高孕周组的内部差异。

- **决策变量与目标函数：**模型的决策变量为 $K - 1$ 个分割点，将序列划分为 K 个连续的子集 $S_1, S_2, \dots, S_K$ 。对于任意一个分组 S_k ，其包含索引 i 至 j 的样本，该组的风险加权方差 $C(i, j)$ 定义为：

$$C(i, j) = \sum_{l=i}^j w(g_l) \cdot (g_l - \mu_k)^2 \quad (12)$$

其中， μ_k 是该分组 S_k 的风险加权平均孕周，计算公式为：

$$\mu_k = \frac{\sum_{l=i}^j w(g_l) \cdot g_l}{\sum_{l=i}^j w(g_l)} \quad (13)$$

最终，我们的优化目标是最小化所有 K 个组的风险加权方差之和：

$$\min Z = \sum_{k=1}^K C(i_k, j_k) \quad (14)$$

(III) 求解算法与推荐值确定 该一维最优分割问题具有最优子结构特性，适合采用动态规划进行求解。

- **动态规划求解：**定义状态 $DP[k][j]$ 表示将前 j 个数据点划分成 k 个组所能达到的最小总代价。状态转移方程为：

$$DP[k][j] = \min_{k-1 \leq i < j} \{DP[k-1][i-1] + C(i, j)\} \quad (15)$$

边界条件为 $DP[1][j] = C(1, j)$ 。通过自底向上填充 DP 表，最终得到全局最优解 $DP[K][n]$ ，并回溯得到对应最优分割方案。

- **组内代表孕周的确定：**在确定了最优的 BMI 分组区间 S_k 后，我们需要为该组指定一个统一的推荐孕周。我们没有采用对异常值敏感的加权均值 μ_k ，而是采用了更为

稳健的风险加权中位数作为最终的推荐值。其计算方法为：将组内的推荐孕周 g_i 按从小到大排序，找到一个临界点 g_{best} ，使得所有小于等于它的孕周的风险权重之和，恰好达到该组总风险权重的 50%。这个值更能代表组内的集中趋势，不易受极端高或低孕周值的影响。

5.3 求解结果与误差分析

本小节旨在系统呈现 GLMM 的求解结果与动态规划分组方案，并对模型的预测性能与推荐时点的可靠性进行严谨评估。具体而言，首先通过剖面概率曲线、联合效应热力图与最优时点规则曲线三类可视化分析，深入揭示孕周、BMI 与达标概率间的定量关系与交互模式。随后，基于 $p^* = 0.90$ 的决策规则，应用动态规划算法得到最优 BMI 分组及对应推荐检测时点，形成可直接应用的临床方案。最后，从预测不确定性及概率校准度两个维度，对模型在高 BMI 区域的外推可靠性及整体预测准确性进行误差分析与诊断，确保推荐方案的稳健性与临床适用性。

5.3.1 模型结果与可视化分析

基于广义线性混合模型（GLMM）的拟合结果，我们获得了达标概率与孕周、BMI 之间的定量关系。为进一步揭示变量间的相互作用模式并为后续分组提供依据，本节从三个维度对模型结果进行可视化分析与解读。

(I) 剖面概率曲线分析（图9） 如图9所示，达标概率随孕周单调上升，但 BMI 越高，整条概率曲线越系统性地向下平移，这表明高 BMI 主要通过降低整体达标基线来延迟最优检测时点。此外，预测的 95% 置信区间在早孕期更宽，而后逐渐收窄，反映了早期预测的不确定性更高，后期预测则更稳定。因此，图中代表高置信度的水平参考线与不同 BMI 曲线的交点，即为各群体在理论上为保证成功率所需的最早可检测孕周。




图 9 不同 BMI 分位数下，达标概率随孕周变化的剖面曲线

(II) 联合效应热力图分析 (图10) 图10的热力图与等概率线直观地揭示了孕周与 BMI 间的可替代性：等概率线呈左下-右上走向，表明可通过推迟孕周来补偿高 BMI 带来的负面影响，这为个体化决策提供了灵活性。此外，图中概率色阶的梯度变化表明，在 16-22 周区间内推迟检测的“边际收益”最高，而在极端高 BMI 区域则呈现收益递减。整个概率场形态平滑，与问题一的模型设定相符，未见强烈的高阶非线性特征。




图 10 孕周与 BMI 对达标概率的联合效应热力图及等概率线

(III) 最优时点规则曲线 (图11) 该图将二维的联合效应信息凝练为一维的可执行规则。它展示了为达到特定置信水平 p^* (0.80, 0.90, 0.95)，所需的最早达标孕周 gw^* 随 BMI 变化的函数关系。该曲线严格单调递增，表明所需的最早达标孕周随 BMI 增加而近似线性地推迟。代表不同置信水平的多条曲线近乎平行，直观地体现了决策中更高保障-更晚检测的权衡关系：为确保更高的检测可靠性，对于同一 BMI 的孕妇，建议的检测孕周需相应推迟。




图 11 不同置信水平下，最早达标孕周 (gw^*) 与 BMI 的关系

5.3.2 动态规划分组结果与时点推荐

基于 $p^* = 0.90$ 的决策规则曲线（图11），在权衡检测的可靠性与时效性后，我们应用上一节的动态规划模型进行 BMI 最优分组。最终得到的分组方案及推荐的 NIPT 检测时点如表4所示。

表 4 基于动态规划优化的 NIPT 最优时点推荐方案 ($p^* = 0.90$)

建议分组	BMI 范围 (kg/m ²)	推荐最佳 NIPT 时点
标准组	< 33.8	第 12 周
偏高组之一	33.8 – 34.8	第 13 周
偏高组之二	34.8 – 35.7	第 14 周
高风险组	35.7 – 36.5	第 15 周
极高风险组	> 36.5	第 15 周末或第 16 周初

5.3.3 模型可靠性与误差影响分析

一个完备的临床推荐方案不仅需要给出最优决策，更需对其潜在的预测不确定性及误差鲁棒性进行严格评估。本研究从预测不确定性与模型校准度两个维度，对上述分组方案的可靠性进行深入分析。

(I) 预测不确定性分析 检测误差与模型局限性的首要体现是预测值的不确定性。如图11所示，预测的置信区间宽度随 BMI 的增高而显著扩大。其根本原因在于：训练数据集中高 BMI 样本的相对稀疏性，导致模型在此区域进行统计推断时，估计方差增大，置信度自然降低。该分析提示，对于 BMI > 36.5 kg/m² 的“极高风险组”，所推荐的检测时点——第 15 周末或第 16 周初，应被视为一个参考范围而非绝对精确值。

(II) 模型概率校准度分析 为评估模型输出概率的绝对准确性，我们绘制了模型的校准曲线，如图12所示。




图 12 模型预测概率与实际观测频率的校准图

该图将样本按预测概率分为 10 箱，比较每箱的平均预测概率与真实达标率。理想情况下，所有点应落在 45° 对角线上。对校准曲线的分析可得出以下结论：

- **整体表现良好：**如图所示，我们的校准曲线整体贴近 45° 参考线，说明 GLMM 模型输出的概率在绝对尺度上具有良好的准确性。例如，当模型预测概率为 80% 时，该群体中真实的达标率也接近 80%。
- **局部存在轻微高估：**在高端概率区间（预测概率 > 0.9）出现轻度“过度自信”，即预测值略高于观测值。这种偏差可能源于两方面，一是将连续的 Y 染色体浓度在阈值 0.04 处进行二分化所固有的信息损失，二是高概率区间往往对应高 BMI 或高孕周，这些区域样本量相对较少，可能导致模型估计出现轻微偏倚。

综合来看，尽管在高概率区域存在轻微高估，但模型整体表现出优异的校准性能，证明其预测结果是可靠且可信的。预测不确定性分析则明确了方案在数据稀疏区域的局限性。二者共同构成了对推荐方案可靠性的全面评估。

六、问题三的模型建立和求解

6.1 问题分析

问题三旨在基于问题二所建立的 BMI 二元分类决策模型，进一步引入身高、体重、年龄、测序质量指标等多维因素，构建一个能够动态预测胎儿 Y 染色体浓度首次达标时间、并据此制定差异化 NIPT 检测时点推荐方案的优化模型。具体而言，本节首先在对多维度特征数据进行可视化分析与预处理的基础上，深入挖掘各因素与达标时间的潜在关系。

随后，本节构建了基于梯度提升的生存分析模型（GBDT-Survival）。该模型在问题二的基础上进一步综合考虑了多维特征的复杂交互效应、右删失数据处理、时间依赖性等关键约束条件，以及不同孕周检测成功率的临床要求。模型能够输出个体化的生存函数，精准预测每位孕妇在不同孕周的达标概率。

接下来，采用均衡型和保障型两种决策策略，针对不同风险偏好的临床场景求解最优检测时点，并通过生存曲线可视化展示预测结果。该方案在多重约束条件下有效实现了检测成功率的最大化与临床风险的最小化。最后，通过动态规划算法对连续 BMI 变量进行最优离散化分组，形成了一套完整的、基于数据驱动的分层推荐方案，为临床实践提供了更加精细化的决策支持。

6.2 多因素生存分析模型的建立

本小节旨在构建一个综合多因素预测胎儿 Y 染色体浓度首次达标时间的生存分析模型。首先将临床问题映射至生存分析框架，明确事件、时间、删失等概念，整合生理与测序指标构成特征向量。随后采用梯度提升生存模型捕捉变量间复杂非线性关系，生成个体化生存函数。在此基础上，提出“保障型”与“均衡型”两种最优时点决策策略，以适应不同临床风险偏好。最后，通过动态规划算法实现 BMI 最优离散分组，为各群体确定统一推荐检测时点，形成一套完整、数据驱动且稳健的 NIPT 时点推荐方案。

6.2.1 生存分析框架定义

我们将问题场景映射到生存分析的框架中，定义如下核心要素：

- **事件**：定义为胎儿 Y 染色体浓度首次达到或超过 4% 的检测时刻。
- **时间**：即生存时间，在此问题中指的是首次达标孕周。
- **删失**：对于末次观测时仍未达标的样本，其真实达标时间未知，标记为右删失 $\delta = 0$ ；已观测到事件的样本标记为 $\delta = 1$ 。
- **特征变量**：将题目要求的所有因素，包括个体生理特征 BMI、年龄、身高、体重和测序质量指标 GC 含量、比对比例、重复率、唯一比对读段数等，共同构成模

型的输入特征向量 $\mathbf{X}$ 。

6.2.2 梯度提升生存模型

为有效捕捉多因素之间复杂的非线性关系, [5] 我们采用梯度提升生存模型 (GBDT-Survival) 作为核心预测工具。该模型具有以下优势: (1) 能够有效处理非线性效应与多重协变量的交互作用; (2) 能够为每个个体生成定制化的生存曲线; (3) 在样本规模有限且存在删失的情况下, 相比参数模型 (如 Cox PH) 表现出更强的鲁棒性与灵活性。该模型通过迭代拟合一系列决策树 $h_m(\cdot)$, 来逼近累积风险函数 $H(t|\mathbf{X})$, 其数学形式如下:

$$H(t|\mathbf{X}) = \sum_{m=1}^M \nu \cdot h_m(\mathbf{X}, t) \quad (16)$$

其中 M 为决策树的总数, ν 收缩学习率用于控制每棵树贡献, 防止过拟合。相应的生存函数 $S(t|\mathbf{X})$ 则由累积风险函数通过以下关系导出:

$$S(t|\mathbf{X}) = \exp \{-H(t|\mathbf{X})\} \quad (17)$$

6.2.3 最优时点决策策略

基于个体化的生存函数预测 $\hat{S}(t|\mathbf{X})$, 我们定义了两种最优 NIPT 时点决策策略, 以服务于不同的临床风险偏好。

- **保障型**: 该策略优先确保检测的高可靠性, 是一种保守方案。其定义为寻找满足群组平均达标概率首次超过 90% 阈值的最早孕周:

$$t_{\text{prot}}^* = \min \{t \in [10, 27] \mid 1 - \bar{S}_G(t) \geq 0.90\} \quad (18)$$

其中 $\bar{S}_G(t) = |G|^{-1} \sum_{i \in G} \hat{S}(t|\mathbf{X}_i)$ 代表分组 G 内在孕周 t 的平均预测未达标概率。

- **均衡型**: 该策略旨在权衡“过早检测导致的失败风险”与“过晚检测带来的临床风险”, 通过最小化一个定义在孕周 t 上的综合成本函数 $C_G(t)$ 来寻找最优时点:

$$t_{\text{bal}}^* = \underset{t \in [10, 27]}{\operatorname{argmin}} C_G(t) \quad (19)$$

综合成本函数 $C_G(t)$ 由以下组件构成：

$$1. \text{ 固有失败风险: } P_{\text{inherent}}(t) = \bar{S}_G(t) \quad (20)$$

$$2. \text{ 早检技术风险: } P_{\text{early}}(t) = \gamma \exp(-\delta \cdot (t - 10)) \cdot \mathbb{I}(t \geq 10) \quad (21)$$

$$3. \text{ 晚检风险权重: } w_{\text{late}}(t) = \begin{cases} 1.0, & t \leq 12 \\ 3.0, & 12 < t \leq 27 \\ 10.0, & t > 27 \end{cases} \quad (22)$$

参数依据先验知识设定 ($\gamma = 0.25, \delta = 0.35$)。早检风险模拟了孕早期因技术因素导致的失败概率，该概率随孕周增加而指数衰减；晚检权重则量化了随孕周增加而急剧升高的临床风险。

总成本函数 $C_G(t)$ 定义为早检失败概率与晚检权重的加权和：

$$C_G(t) = [P_{\text{inherent}}(t) + P_{\text{early}}(t) - P_{\text{inherent}}(t) \cdot P_{\text{early}}(t)] + \lambda \cdot w_{\text{late}}(t) \quad (23)$$

式中，方括号内为考虑两类失败风险并存后的总失败概率， λ 为调节晚检风险重要性的超参数。

6.3 模型求解与结果分析

本小节旨在系统评估梯度提升生存模型模型性能，深入解读预测结果，并形成基于 BMI 分层的 NIPT 时点推荐方案。分析遵循一下下流程：首先从区分度与校准度两方面量化评估模型预测可靠性；随后通过可视化手段验证预测一致性并探究 BMI 的影响；最后，综合模型输出、决策策略与动态规划算法，生成面向不同临床偏好的“双轨制”推荐方案。

6.3.1 模型性能评估

我们从区分度和校准度两个维度对优化后的梯度提升生存模型进行综合评估，以量化其预测性能，关键结果如下表所示。

表 5 优化后 GBDT-Survival 模型性能与关键参数摘要

评估与参数类别	数值或设定
核心性能指标	
Harrell' s C-index (Test)	0.541
Integrated Brier Score (IBS)	0.094
模型与分析参数	
模型超参数	learning_rate=0.1, n_estimators=400, max_depth=3
Y 浓度达标阈值 (τ)	$\geq 4.0\%$
时间网格	10–30 周, 步长 0.5 周
BMI 分组数 (K)	4 组 (基于动态规划)
保障型策略目标 (P)	$\geq 90\%$

性能评估表明：

- **区分度：**模型在测试集上的 Harrell' s C-index 为 0.541，该值超过了 0.5 的随机水平，表明模型已具备对不同孕妇达标时间进行正确排序的基础预测能力。
- **校准度：**Integrated Brier Score (IBS) 为 0.094，该数值远优于 0.25 的随机基准，表明模型预测的生存概率曲线在整体上具有较高的准确度和可靠性。

综合来看，优化后的模型虽在区分度上仍有提升空间，但其预测结果已足够稳健，可作为后续时点优化与分组决策的有效依据。表中同时列出了经调优确定的关键模型与分析参数（学习率 0.1、400 棵决策树、最大深度 3），确保了研究过程的可重复性。

6.3.2 预测结果解读与可视化

(I) 预测与观测时间的一致性 为评估模型的预测一致性，我们将模型预测的“中位达标孕周”与实际观测到的“事件/删失时间”进行比较，如图13所示。




图 13 预测中位达标时间与实际观测时间的比较

整体上，大多数已发生事件的观测点（蓝色实心点）分布在 45° 参考线附近，说明模型的预测值与实际首次达标时间具有较好的一致性。同时，在早孕阶段（10-13 周），数据点离散程度较高，这与孕早期胎儿游离 DNA 浓度波动较大的生物学事实相符，反映了模型在此阶段固有的预测不确定性。

(II) BMI 对达标时间的影响 为探究 BMI 的核心影响，我们绘制了低、中、高三位代表性 BMI 孕妇的生存曲线，如图14。




图 14 不同 BMI 水平下的个性化生存曲线

所有曲线均随孕周增加而单调递减；关键的发现在于，随着 BMI 的升高，生存曲线整体右移，即高 BMI 孕妇需要更长的孕周才能达到同等的达标概率。这从视觉上证实了 BMI 是影响达标进程速率的决定性因素。

6.3.3 最优时点生成、分组与最终方案

(I) 个性化时点序列生成 基于第6.2.2节训练完成的梯度提升生存模型，我们为每位孕妇样本生成了其个性化的最优推荐时点 t_i^* ，从而构成与 BMI 值对应的决策序列 $\{(b_i, t_i^*)\}_{i=1}^N$ 。此序列将作为分组优化的直接输入。

(II) 动态规划分组优化 随后，需将连续决策序列 $\{(b_i, t_i^*)\}$ 转化为离散的、临床可操作的 BMI 分组方案。该优化问题的数学形式——包括目标函数、风险权重函数 $w(\cdot)$ 及动态规划求解算法——与问题二完全一致（详见第5.2.2节），其核心目标仍是最小化组内风险加权方差。本研究与此前工作的唯一区别在于输入序列：此处为源自梯度提升生存模型的 $\{(b_i, t_i^*)\}$ 。

我们直接应用既定算法求解，最终得到最优 BMI 分组区间及组内代表时点，如表6所示。

表 6 基于多因素生存分析与动态规划的分组方案（均衡策略）

分组	BMI 范围 (kg/m ²)	推荐孕周
组 I	< 28.5	第 12.2 周
组 II	28.5 – 31.1	第 13.1 周
组 III	31.1 – 33.8	第 14.0 周
组 IV	33.8 – 36.0	第 15.3 周
组 V	> 36.0	第 16.5 周

6.3.4 最终推荐方案与讨论

综合应用梯度提升生存预测模型、两种决策策略及动态规划算法，我们得到了数据驱动的 NIPT 时点推荐方案。动态规划模型在 BMI ≈ 29.2 处识别出一个显著拐点，表明最优时点在此阈值附近发生阶跃式变化。

基于拐点发现，我们对算法产出进行了合并简化，最终形成了如图15所示的宏观推荐层级。




图 15 BMI 分组方案：推荐 NIPT 检测周数（均衡型 vs 保障型）

该方案揭示了以下结论：

- **总体趋势：**随着 BMI 区间的升高，无论是“均衡型”还是“保障型”策略，其推荐的最佳孕周均呈现出明显的推迟趋势，再次验证了 BMI 是影响 NIPT 最早可检测时间的核心因素。
- **策略权衡：**对于所有 BMI 分组，“保障型”策略（确保至少 90% 达标率）推荐的孕周，均不早于“均衡型”策略。这清晰量化了“追求更高可靠性”所需付出的“时间成本”。
- **关键决策点：**策略差异在最高 BMI 组别）中表现得最为显著，为高风险人群提供了明确的风险-收益权衡选项。

综上，该双轨制方案为临床决策提供了兼顾效率与可靠性的个性化决策支持：对于常规情况或对检测效率有要求的场景，可采用均衡型方案；而对于希望最大化单次检测成功率、规避复检风险的孕妇尤其是高 BMI 人群，则应采纳保障型方案。

七、问题四的模型建立和求解

7.1 问题分析

问题四的核心任务是构建一个针对女胎染色体非整倍体异常的智能判别模型。该任务面临三大关键问题：(1) 异常样本在真实场景中极为稀少，导致模型难以学习少数类的判别特征；(2) 漏诊的代价远高于误诊，要求模型必须优先保证极高的召回率；(3) 同一孕妇可能存在多次检测记录，导致数据存在嵌套结构，需严格防止信息泄露以确保模型评估无偏。

为系统应对上述挑战，本研究设计了一套综合解决方案：首先进行严谨的数据预

处理与特征工程；随后选用擅长处理表格数据的 TabNet 作为核心架构，并引入 Focal Loss 以应对类别不平衡；采用分层分组交叉验证确保评估严谨性；最终，通过最大化 F2-score 自适应确定决策阈值，优先保障高召回率，从而满足临床需求。

7.2 模型建立与求解策略

本小节构建一个能够精准判别女胎染色体异常的、鲁棒的分类模型。为此，我们首先构建了一个包含判别指标、测序质量指标与孕妇生理特征的多维度特征体系，并进行了严格的标准化与缺失值处理，以确保输入数据的质量与一致性。随后，为应对本问题中严重的类别不平衡挑战，[6] 我们选用了 TabNet 深度学习模型作为核心分类器，并为其定制了 Focal Loss 作为损失函数，旨在引导模型更专注于学习数量稀少的异常样本，从而提升模型的召回表现。

7.2.1 特征工程与数据预处理

为后续的分类模型建立，我们对数据进行了系统的特征工程与预处理，主要包括：

- **核心判别特征**：选取 13、18、21 及 X 染色体的 Z 值 ($Z_{13}, Z_{18}, Z_{21}, Z_X$) 与 X 染色体浓度 (X_conc) 作为关键的生物学判别信号。
- **测序质量特征**：纳入 GC 含量、比对比例 (map_ratio)、重复比例 (dup_ratio)、过滤读数比例 ($filter_ratio$) 及对数化后的唯一比对读段数，用于监控数据质量对模型判断的影响。
- **生理特征**：引入 BMI、年龄、身高、体重、孕周等孕妇个体特征，用于捕捉个体差异。
- **标准化与插补**：所有连续特征均进行 Z-score 标准化，比例特征归一化至 $[0,1]$ 区间。缺失值则严格使用**训练集**的中位数进行填补，以杜绝在预处理过程中的信息泄露。
- **训练集不平衡处理**：针对异常样本稀少的严重类别不平衡问题，我们仅对训练集中的正类（异常样本）进行轻量过采样，以增加模型学习到异常特征的机会，同时避免在验证集和测试集上引入偏差，确保了模型评估的公正性。

7.2.2 预测模型：TabNet 与 Focal Loss

为捕捉特征间的复杂关系，我们选用基于注意力机制的 TabNet 作为核心分类器。其优势在于能提供特征重要性解释，并适用于表格数据。为应对类别不平衡，我们在算法层面引入 Focal Loss 作为模型的损失函数：

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (24)$$

其中 p_t 为模型预测概率, $\gamma = 2$ 用于降低易分类样本的损失贡献, 使模型聚焦于难分的异常样本。模型超参数设定为: $(n_d, n_a) = (16, 16)$, 4 个决策步骤, 并施加稀疏正则化。训练采用带步进衰减的学习率调度与早停机制, 以防止过拟合。为验证 TabNet 模型的优越性, 训练了一个带 L1 正则化的逻辑回归模型作为参照基线。

7.2.3 决策阈值优化策略：最大化 F2-Score

在产前筛查这类高风险决策场景中, 模型的评估标准不能单纯追求准确率, 而必须优先考虑对异常样本的检出能力, 即召回率。传统的固定阈值 0.5 通常无法满足这一要求, 因为它并未考虑假阴性与假阳性的不对称成本。

为精准契合“宁可误诊、不可漏诊”的临床安全准则, 本文摒弃了固定阈值方案, 转而采用在验证集上最大化 F2-Score 以自适应地搜寻最优决策阈值。F2-Score 是精确率与召回率的加权调和平均:

$$F_2 = (1 + 2^2) \cdot \frac{P \cdot R}{(2^2 \cdot P) + R} = 5 \cdot \frac{P \cdot R}{4P + R} \quad (25)$$

其通过权重参数 $\beta = 2$, 赋予了召回率两倍于精确率的重要性。以 F2-Score 为优化目标, 能够确保我们最终选定的决策阈值, 是在保障极高检出率前提下的最优平衡点, 从而最大化模型在实际应用中的安全性与临床价值。

7.3 求解结果与综合分析

7.4 求解结果与综合分析

本小节旨在从模型区分能力、概率校准性、决策阈值效用及特征可解释性四个维度, 系统性地评估我们所构建的女胎染色体异常判别模型的综合性能。我们首先通过 ROC 与 PR 曲线, 将 TabNet 模型与基线模型进行宏观性能对比, 以验证其整体的区分能力; 随后, 我们分析了模型在默认阈值下的决策表现, 以论证优化决策阈值的必要性; 最后, 我们展示了在高召回率 (F2-score 最优) 策略下的最终模型性能, 并结合特征重要性分析, 对其决策依据进行了深入解读。

(I) ROC 与 PR 曲线分析 模型总体性能对比结果如图16和图17所示。ROC 曲线表明, TabNet 模型具备优异的全局区分能力, 其 AUC 值达到 0.945, 显著优于 L1 正则化逻辑回归基线 (AUC=0.871), 而在更能反映不平衡数据分类性能的 PR 曲线中, TabNet 的优势更为明显 (AP=0.797 vs. 基线 0.590)。这两项结果充分证明了 TabNet 模型在处理复杂特征关系与数据嵌套结构方面的卓越能力, 成功应对了挑战一与挑战三。




图 16 ROC 曲线对比




图 17 PR 曲线对比

(II) 决策阈值的必要性分析 为论证阈值优化的必要性，我们分析了模型在默认 0.5 阈值下的表现。如图18所示，模型的校准曲线虽在低概率区间存在一定程度的偏高预测，但整体仍然可靠。然而，即便有此基础，模型在默认 0.5 阈值下的决策表现却严重失衡 (图19)：该阈值虽能达到 94.8% 的极高召回率，58 例异常中仅漏诊 3 例，但代价是产生了 112 例假阳性，导致精确率仅为 32.9%。如此高的误诊率严重影响了方案的临床实用性，因此，为寻找召回率与精确率的最佳平衡点，对决策阈值进行优化至关重要。




图 18 模型校准曲线




图 19 默认阈值 (0.5) 下的混淆矩阵

(III) 高召回策略下的最终性能与可解释性 为寻找召回率与精确率的最佳平衡点，我们通过在验证集上最大化 F2-score，最终确定了最优决策阈值为 0.58。应用该优化阈值后，模型的最终判别性能在临床实用性上得到了显著提升。具体而言，相较于默认阈值，优化后的方案将假阳性案例从 112 例大幅减少至 44 例，使得精确率从 32.9% 跃升

至 52.7%。尽管这伴随着漏诊数从 3 例增加到 9 例，但召回率仍保持在 84.5% 的高水平，远优于基线模型，实现了在保障高检出率与控制误诊规模间的有效平衡。同时，为进一步提升模型的可解释性与临床应用的可信度，我们分析了 TabNet 模型给出的特征重要性排序。这两部分核心结果分别由图20和图21进行可视化呈现。




图 20 F2 最优阈值下的混淆矩阵




图 21 Top-15 特征重要性

7.5 女胎异常判定方法

针对问题四的要求，我们最终提出的“女胎异常判定方法”并非一个孤立的预测模型，而是一个包含了三个核心步骤的完整方案。该方案旨在为临床提供一个清晰、可靠且安全的决策流程：

- 1. **第一步：模型概率预测：**首先，使用我们训练好的 TabNet 模型，对输入的孕妇多维特征数据进行分析，并为每一份样本输出其胎儿染色体异常的预测概率。
- 2. **第二步：优化阈值决策：**然后，我们将上一步输出的连续概率转化为正常或异常的初步判断。我们应用经 F2-score 优化得到的决策阈值（本研究 中为 0.58），当样本的预测概率高于该阈值时，初步判定为异常，反之则为正常。
- 3. **第三步：辅助质控验证：**最后，我们为系统增加了一道重要的安全检查。该环节基于模型的特征重要性分析，对关键的测序质量指标如 filter_ratio、map_ratio 设定预警阈值。当一个被初步判定为正常的样本，其质控指标却不达标时，系统将修正初步结论，并给出最终建议：因样本质量不佳，结果不确定性高，建议重新检测。

这三个步骤形成了一个模型判读 → 质控验证的决策流程。该流程不仅通过优化阈值来保证高检出率，更通过质控环节的设计，为核心预测模型增加了一道额外的安全检查。这种做法能够有效避免因数据质量问题而导致的潜在漏诊风险，从而显著提升了我们最终判定方法在实际应用中的安全性和准确性。

八、模型评价

8.1 模型的优点与创新

1. **完整性**：本文针对四个问题，构建了逻辑递进的模型体系。从问题一的基础关系探索 (LMM)，到问题二、三的时点优化 (GLMM、生存分析)，再到问题四的智能判别 (TabNet)，形成了一个环环相扣的完整解决方案。
2. **针对性与创新性**：模型选择具有针对性。我们运用了混合效应模型处理重复测量数据，生存分析方法预测事件时间，TabNet 模型应对不平衡分类问题，并引入动态规划算法实现最优分组，解决了各环节的技术问题。
3. **可靠性与可解释性**：所有模型均通过的交叉验证或统计检验，确保了结论的可靠性。最终输出的结果，如推荐时点方案、生存曲线和模型特征重要性等，兼具了较好的预测性能与清晰的可解释性。

8.2 模型的缺点与改进

1. **模型假设的局限性**：部分模型（如 LMM）基于线性假设，可能未能完全捕捉复杂的非线性生物学关系。未来可以尝试非参数或非线性模型进行改进，以提升拟合精度。
2. **训练数据的局限性**：数据集中高 BMI 及异常样本的数量相对稀少，这在一定程度上限制了模型在这些关键群体的预测精度。未来若能扩充相关样本量，将是提升模型泛化能力的关键。

参考文献

- [1] 魏智芳, 侯东霞, 王晓华. 无创产前筛查中影响胎儿游离 DNA 浓度的因素研究进展[J]. 检验医学与临床, 2025, 22(06):850-854+859.
- [2] 余俊飞, 赵慧秀. 一类线性混合模型的广义估计方程方法应用[J/OL]. 兰州文理学院学报 (自然科学版), 2021, 35(04):1-4. DOI: 10.13804/j.cnki.2095-6991.2021.04.001.
- [3] 姜海燕. 基于 Logistic 回归分析探讨无创产前检查筛查失败的影响因素[D/OL]. 大连医科大学, 2021. DOI: 10.26994/d.cnki.gdlyu.2021.001013.
- [4] 薛煌铠, 宋佳怡, 苗育睿. 基于多目标优化模型的扇叶最优分组与排列方案[J/OL]. 现代信息科技, 2024, 8(07):100-106. DOI: 10.19850/j.cnki.2096-4706.2024.07.022.
- [5] CHEN Y, JIA Z, MERCOLA D, et al. A gradient boosting algorithm for survival analysis via direct optimization of concordance index[J]. Computational and Mathematical Methods in Medicine, 2013, 2013:873595.
- [6] TERMEH R V S, NIARAKI S A, SOROOSHIAN A, et al. Spatial mapping of land susceptibility to dust emissions using optimization of attentive interpretable tabular learning (tabnet) model[J]. Journal of Environmental Management, 2024, 358:120682.
- [7] DEEPSEEK. Deepseek-r1-0528[M]. [S.l.]: 深度求索 (DeepSeek) , 2025.

附录 A 支撑材料的文件列表

文件名	功能描述
q1.py	问题一代码
q2.py	问题二代码
q3.py	问题三代码
q4.py	问题四代码
代码运行说明.txt	运行代码说明
AI 工具使用详情.pdf	ai 使用说明
figures	论文中的图片

附录 B 代码

q1.py

```
1 # --- 问题一模型：核心部分代码 ---
2 X_cols = ["gw_z", "bmi_z", "gw_x_bmi_z", "age_z", "gc_z", "map_z", "
   dup_z", "log_uniq_z"]
3 X = sm.add_constant(dat[X_cols])
4 y_vec = dat["logit_y"]
5 groups = dat["id"]
6
7 fit_info = {}
8 used_model = None
9 try:
10     model = MixedLM(endog=y_vec, exog=X, groups=groups)
11     result = model.fit(reml=False, method="lbfgs", maxiter
   =200)
12     used_model = "MixedLM"
13     fit_info["converged"] = bool(result.converged)
14     fit_info["nobs"] = int(result.nobs)
15 except Exception as e:
16     used_model = "OLS_fallback"
17     fit_info["MixedLM_error"] = str(e)
18     result = sm.OLS(y_vec, X).fit()
19
```

```

20 # --- R2 ---
21 if used_model == "MixedLM":
22     yhat_fixed = np.asarray(np.dot(X, result.fe_params))
23     var_fixed = np.var(yhat_fixed, ddof=1)
24     try:
25         var_random = float(result.cov_re.iloc[0,0])
26     except Exception:
27         var_random = 0.0
28     resid = y_vec - result.fittedvalues
29     var_resid = np.var(resid, ddof=1)
30     total = var_fixed + var_random + var_resid
31     r2_marginal = float(var_fixed/total) if total>0 else np.
nan
32     r2_conditional = float((var_fixed+var_random)/total) if
total>0 else np.nan
33 else:
34     resid = y_vec - result.fittedvalues
35     r2_marginal = float(result.rsquared) if hasattr(result, "
rsquared") else np.nan
36     r2_conditional = r2_marginal

```

q2.py

```

1 # --- 问题二模型：核心部分代码 ---
2 # === 小工具：列名标准化 / 孕周解析 / 比例修正 ===
3 def parse_week_to_float(x):
4     if pd.isna(x): return np.nan
5     s = str(x).strip().lower().replace('周','w').replace('d','
')
6     m = re.match(r'^(\d+)\s*w+(\d+)$', s)
7     if m: return int(m.group(1)) + int(m.group(2))/7.0
8     m = re.match(r'^(\d+)\s*\+\s*(\d+)$', s)
9     if m: return int(m.group(1)) + int(m.group(2))/7.0
10    try: return float(s)
11    except: return np.nan
12

```

```

13 def normalize_rate(s):
14     v = pd.to_numeric(s.astype(str).str.replace("%","").str.
15         replace(",",""), errors="coerce")
16     return v/100.0 if (np.nanmax(v) > 1.5) else v
17 # === 概率模型 (gw 单调非减 + Isotonic校准) ===
18 class AchieveProbModel:
19     def __init__(self, feature_cols, monotonic_gw_idx=None):
20         self.feature_cols = feature_cols
21         self.monotonic_gw_idx = monotonic_gw_idx
22         self.scaler = StandardScaler()
23         self.clf = None
24         self.iso = None
25         self.use_histgb = True
26
27     def _build_classifier(self):
28         if self.use_histgb:
29             n_features = len(self.feature_cols)
30             mono = [0]*n_features
31             if self.monotonic_gw_idx is not None:
32                 mono[self.monotonic_gw_idx] = 1 # gw 单调非减
33             return HistGradientBoostingClassifier(
34                 max_depth=3, learning_rate=0.08, max_iter=500,
35                 monotonic_cst=mono, l2_regularization=1e-3
36             )
37         else:
38             return GradientBoostingClassifier(
39                 learning_rate=0.06, n_estimators=600,
40                 max_depth=3, subsample=0.9
41             )
42
43     def fit(self, df, label_col='achieve'):
44         X = df[self.feature_cols].astype(float).values
45         y = df[label_col].astype(int).values
46         Xs = self.scaler.fit_transform(X)
47         # 先试HGB(带单调约束), 不行再回退GBDT

```

```

46         try:
47             self.use_histgb = True
48             self.clf = self._build_classifier()
49             self.clf.fit(Xs, y)
50         except Exception:
51             self.use_histgb = False
52             self.clf = self._build_classifier()
53             self.clf.fit(Xs, y)
54
55         # Holdout 里做Isotonic校准（避免概率偏硬）
56         Xtr, Xval, ytr, yval = train_test_split(Xs, y,
test_size=0.25, stratify=y, random_state=42)
57         self.clf.fit(Xtr, ytr)
58         raw = self.clf.predict_proba(Xval)[: , 1]
59         self.iso = IsotonicRegression(out_of_bounds='clip')
60         self.iso.fit(raw, yval)
61
62     def predict_proba(self, df):
63         X = df[self.feature_cols].astype(float).values
64         Xs = self.scaler.transform(X)
65         raw = self.clf.predict_proba(Xs)[: , 1]
66         if self.iso is not None:
67             cal = self.iso.transform(raw)
68             return np.clip(cal, 1e-5, 1-1e-5)
69         return np.clip(raw, 1e-5, 1-1e-5)

```

q3.py

```

1  # --- 问题三模型：核心部分代码 ---
2  def optimize_bmi_segments(self, subject_data, survival_matrix)
    :
3      bmi_order = np.argsort(subject_data["BMI"].values)
4      sorted_bmi = subject_data["BMI"].values[bmi_order]
5      n_subjects = len(bmi_order)
6
7      segment_costs = np.full((n_subjects, n_subjects), np.nan)

```

```

8     segment_weeks = np.full((n_subjects, n_subjects), np.nan)
9
10    for i in range(n_subjects):
11        current_indices = []
12        for j in range(i, n_subjects):
13            current_indices.append(bmi_order[j])
14            cost_vector, optimal_week, min_cost = self.
calculate_group_cost(current_indices, survival_matrix)
15            segment_costs[i, j] = min_cost
16            segment_weeks[i, j] = optimal_week
17
18    dp_table = np.full((self.segments_count, n_subjects), np.
inf)
19    predecessor = np.full((self.segments_count, n_subjects),
-1, dtype=int)
20
21    for j in range(n_subjects):
22        dp_table[0, j] = segment_costs[0, j]
23        predecessor[0, j] = -1
24
25    for k in range(1, self.segments_count):
26        for j in range(k, n_subjects):
27            best_value = np.inf
28            best_predecessor = -1
29
30            for t in range(k - 1, j):
31                value = dp_table[k - 1, t] + segment_costs[t +
1, j]
32                if value < best_value:
33                    best_value = value
34                    best_predecessor = t
35
36            dp_table[k, j] = best_value
37            predecessor[k, j] = best_predecessor
38

```

```

39     segment_boundaries = []
40     k, j = self.segments_count - 1, n_subjects - 1
41
42     while k >= 0:
43         t = predecessor[k, j]
44         left = 0 if t == -1 else t + 1
45         segment_boundaries.append((left, j))
46         j = t
47         k -= 1
48
49     segment_boundaries = segment_boundaries[::-1]
50
51     segments_info = []
52     for left, right in segment_boundaries:
53         bmi_min = sorted_bmi[left]
54         bmi_max = sorted_bmi[right]
55         optimal_week = float(segment_weeks[left, right])
56
57         segments_info.append({
58             "idx_l": int(left), "idx_r": int(right),
59             "BMI_min": float(bmi_min), "BMI_max": float(
60                 bmi_max),
61             "week_star": optimal_week
62         })
63
64     return pd.DataFrame(segments_info), segment_boundaries,
65         bmi_order

```

q4.py

```

1  # --- 问题四模型：核心部分代码 ---
2  class FocalLoss(torch.nn.Module):
3      def __init__(self, alpha=None, gamma=2.0, reduction="mean"
4      ):
5          super().__init__()
6          self.alpha = alpha

```

```

6         self.gamma = gamma
7         self.reduction = reduction
8
9     def forward(self, logits, targets):
10         ce = torch.nn.functional.cross_entropy(logits, targets
11 , weight=self.alpha, reduction="none")
12         pt = torch.exp(-ce)
13         loss = (( 1 -pt ) * self.gamma) * ce
14         return loss.mean() if self.reduction == "mean" else
15 loss.sum()
16
17 loss_fn = FocalLoss(alpha=class_weights, gamma=2.0)
18
19 # TabNet参数
20 tabnet_params = {
21     "n_d": 16, "n_a": 16, "n_steps": 4, "gamma": 1.6, "
22     lambda_sparse": 1e-3,
23     "optimizer_params": {"lr": 8e-4, "weight_decay": 1e-5},
24     "mask_type": "entmax"
25 }
26
27 fit_params = {
28     "eval_metric": ["balanced_accuracy"],
29     "max_epochs": 150,
30     "patience": 50,
31     "batch_size": 512,
32     "virtual_batch_size": 128,
33     "num_workers": 0,
34     "drop_last": False
35 }
36
37 # 模型训练
38 device_name = 'cuda' if torch.cuda.is_available() else 'auto'
39 clf = TabNetClassifier(
40     **tabnet_params,

```

```

38     scheduler_params={"step_size": 60, "gamma": 0.9},
39     scheduler_fn=torch.optim.lr_scheduler.StepLR,
40     device_name=device_name
41 )
42
43 clf.fit(
44     X_train=X_train_os, y_train=y_train_os,
45     eval_set=[(X_valid, y_valid)],
46     eval_name=["valid"],
47     loss_fn=loss_fn,
48     **fit_params
49 )
50
51 # F2阈值优化
52 p_valid = clf.predict_proba(X_valid)[:, 1]
53 ths = np.linspace(0.05, 0.95, 91)
54 f2s = [fbeta_score(y_valid, (p_valid >= t).astype(int), beta
55     =2.0) for t in ths]
56
57 best_t = float(ths[int(np.argmax(f2s))])
58
59 # 测试集评估
60 p_test = clf.predict_proba(X_test)[:, 1]
61 y_pred_default = (p_test >= 0.5).astype(int)
62 y_pred_best = (p_test >= best_t).astype(int)
63
64 def evaluate_and_save(prefix, y_true, p, y_pred):
65     auc = roc_auc_score(y_true, p)
66     ap = average_precision_score(y_true, p)
67     cm = confusion_matrix(y_true, y_pred)
68     rpt = classification_report(y_true, y_pred, digits=4)
69     threshold = 0.5 if 'default' in prefix else best_t
70     print(f"{prefix} | AUC={auc:.4f} | AP={ap:.4f} | 阈值={
threshold:.2f}")
71     print(cm)

```

```

71     with open(os.path.join(OUTPUT_DIR, f"{prefix}_metrics.json
    "), "w", encoding="utf-8") as f:
72         json.dump({
73             "AUC": float(auc), "AP": float(ap), "threshold":
threshold,
74             "confusion_matrix": cm.tolist(), "
classification_report": rpt
75         }, f, ensure_ascii=False, indent=2)
76     return auc, ap, cm, rpt
77
78 auc_d, ap_d, cm_d, rpt_d = evaluate_and_save("test_default",
    y_test, p_test, y_pred_default)
79 auc_b, ap_b, cm_b, rpt_b = evaluate_and_save("test_bestT",
    y_test, p_test, y_pred_best)

```